Link para o trabalho https://www.youtube.com/watch?v=c-1cBNhvNq8

Caso o vídeo no youtube não apareça:

https://drive.google.com/drive/folders/1VH9FXUeV4J1nAI1-UWfNzE6h1Vm5PaHM?usp=sharing

O presente trabalho demonstra a aplicação de um autoencoder para a remoção de ruído em sinais biomédicos simulados.

O objetivo deste projeto foi desenvolver um autoencoder para redução de ruído em sinais biomédicos. O modelo é capaz de filtrar diferentes tipos de ruídos adicionados artificialmente a sinais de ECG, EEG, EMG e EOG.

Primeiramente, foi gerado sinais sintéticos representando Eletrocardiogramas (ECG) que simulam a atividade elétrica do coração, Eletroencefalogramas (EEG) que simulam a atividade elétrica do cérebro, Eletromiogramas (EMG) que simulam a atividade elétrica dos músculos e Eletrooculogramas (EOG) que simulam a atividade elétrica dos olhos. Exemplos de equipamentos que representam esses sinais:

- ECG: Monitores cardíacos, Holter.
- EEG: Capacetes de EEG, sistemas de monitoramento de sono.
- EMG: Equipamentos de eletromiografia, dispositivos de reabilitação muscular.
- EOG: Sistemas de rastreamento ocular, dispositivos de estudo do sono

Em seguida, adicionamos diferentes tipos de ruído a esses sinais para simular cenários reais, diferentes tipos de ruído foram adicionados aos sinais gerados. Os tipos de ruído incluem:

- Powerline Noise (Ruído de Linha de Potência)
 - Descrição: Este tipo de ruído é causado pela interferência de redes elétricas, geralmente a 50 ou 60 Hz, dependendo da região.
 - Origem: Fios de energia elétrica nas proximidades de dispositivos biomédicos.
 - Efeito no Sinal: Aparece como uma oscilação senoidal constante no sinal, o que pode mascarar as características do sinal biomédico real.
 - Simulação: Adicionado ao sinal com a equação noise_amplitude * np.sin(2 * np.pi * 50 * t) onde 50 é a frequência da rede elétrica.
- Baseline Wander (Variação de Linha de Base)
 - Descrição: Variação lenta e de baixa frequência que pode ocorrer devido a mudanças na posição dos eletrodos ou respiração.
 - Origem: Movimento do paciente ou mau contato dos eletrodos.
 - Efeito no Sinal: Resulta em uma oscilação de baixa frequência que desloca a linha de base do sinal, dificultando a análise precisa.
 - Simulação: Gerado acumulando uma série de valores normais aleatórios e suavizando o resultado.
- Electrode Motion (Movimento do Eletrodo)

- Descrição: Ruído causado pelo movimento dos eletrodos em contato com a pele.
- Origem: Paciente se movendo ou ajustando os eletrodos.
- Efeito no Sinal: Aparece como picos ou ruídos transitórios, interferindo na precisão do sinal.
- Simulação: Adiciona picos aleatórios no sinal em posições selecionadas aleatoriamente.
- White Noise (Ruído Branco)
 - Descrição: Ruído de espectro plano, ou seja, todas as frequências têm igual intensidade.
 - Origem: Equipamento eletrônico, ambiente circundante ou outras fontes aleatórias.
 - Efeito no Sinal: Introduz variações aleatórias ao sinal que podem obscurecer as características do sinal real.
 - Simulação: Adicionado ao sinal com a equação np.random.normal(0, noise_amplitude, len(signal)).

A função add_noise foi utilizada para adicionar esses ruídos ao sinal original.

Os dados foram preparados para treinamento e teste através da função prepare_data_with_noise , que gerou amostras de sinais ruidosos a partir dos sinais originais.

O autoencoder foi construído utilizando a biblioteca Keras. A arquitetura do autoencoder incluiu:

- Encoder: Camadas densas com regularização L2 e dropout para prevenir overfitting.
- Decoder: Camadas densas para reconstruir o sinal original.

A função build_autoencoder foi utilizada para construir e compilar o modelo.

O modelo foi treinado utilizando um conjunto de dados de treinamento com 70% de divisão para validação. O treinamento foi monitorado usando EarlyStopping para evitar overfitting.

Após o treinamento, o modelo foi avaliado e os sinais denoised foram gerados. A função plot_signals foi utilizada para comparar os sinais originais, ruidosos e denoised, além de mostrar o histórico de erro do modelo.

Conclusão

O autoencoder desenvolvido se mostrou eficaz na redução de ruído em sinais biomédicos sintéticos. As técnicas de regularização e dropout ajudaram a evitar overfitting, e o uso de EarlyStopping garantiu que o modelo não fosse treinado em excesso. Os resultados indicam que a abordagem pode ser aplicada a dados reais, com ajustes adequados.

Este projeto demonstra a viabilidade de usar autoencoders para tarefas de denoising em sinais biomédicos, oferecendo uma base para pesquisas e aplicações práticas.

```
In [ ]: import numpy as np
        import matplotlib.pyplot as plt
        from tensorflow.keras.layers import Input, Dense, Dropout
        from tensorflow.keras.models import Model
        from tensorflow.keras.callbacks import EarlyStopping
        from tensorflow.keras.optimizers import Adam
        from tensorflow.keras.losses import Huber
        from tensorflow.keras.regularizers import 12
        def generate_signal(duration, frequency, signal_type):
            """Generates a synthetic biomedical signal of the specified type."""
            time = np.linspace(0, duration, int(frequency * duration))
            if signal_type == 'ecg':
                heart_rate = 1.2
                signal = (np.sin(2 * np.pi * heart_rate * time) +
                          0.5 * np.sin(2 * np.pi * 2 * heart_rate * time) +
                          0.2 * np.sin(2 * np.pi * 3 * heart_rate * time))
            elif signal_type == 'eeg':
                signal = (np.sin(2 * np.pi * 10 * time) +
                          np.sin(2 * np.pi * 20 * time) +
                          np.sin(2 * np.pi * 30 * time) +
                          np.random.normal(0, 0.1, len(time)))
            elif signal_type == 'emg':
                signal = np.random.randn(len(time))
            elif signal type == 'eog':
                signal = np.sin(2 * np.pi * time) + 0.5 * np.random.randn(len(time))
            else:
                raise ValueError(f"Invalid signal type: {signal_type}")
            return time, signal
        def add noise(signal, noise type, noise amplitude):
            """Adds specific types of noise to a biomedical signal."""
            t = np.arange(len(signal)) / len(signal)
            if noise type == 'powerline':
                noise = noise_amplitude * np.sin(2 * np.pi * 50 * t)
            elif noise_type == 'baseline_wander':
                noise = np.cumsum(np.random.normal(0, 0.1, len(signal))) * noise_amplitu
                noise = np.convolve(noise, np.ones(10) / 10, mode='same')
            elif noise_type == 'electrode_motion':
                num_spikes = int(noise_amplitude * len(signal) / 1000)
                spike_indices = np.random.choice(len(signal), num_spikes, replace=False)
                noise = np.zeros(len(signal))
                noise[spike_indices] = np.random.normal(0, noise_amplitude, num_spikes)
            elif noise_type == 'white_noise':
                noise = np.random.normal(0, noise_amplitude, len(signal))
            else:
                raise ValueError(f"Invalid noise type: {noise type}")
            return signal + noise
        def prepare_data_with_noise(signal, num_samples, noise_amplitude):
            """Prepares training data by adding various noise types to the original sign
            noise_types = ['powerline', 'baseline_wander', 'electrode_motion', 'white_no
```

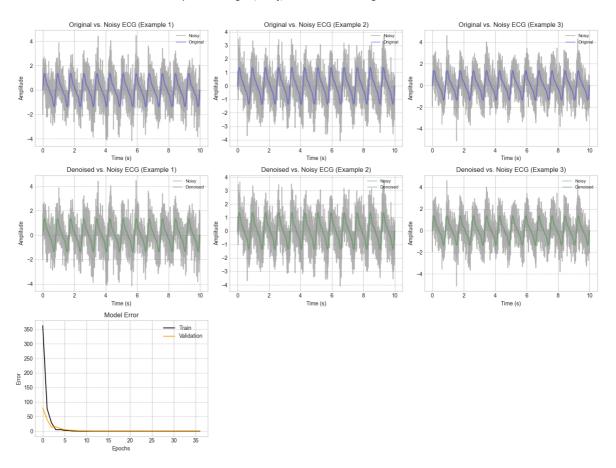
```
X_train = np.tile(signal, (num_samples, 1))
    X_{noisy} = []
    for _ in range(num_samples):
        noise_type = np.random.choice(noise_types)
        noisy_signal = add_noise(signal, noise_type, noise amplitude)
        X_noisy.append(noisy_signal)
    return X_train, np.array(X_noisy)
def prepare_data(duration, frequency, signal_type, num_samples, noise_amplitude)
    """Prepares training and noisy data for the specified signal type."""
    time, signal = generate_signal(duration, frequency, signal_type)
   X_train, X_noisy = prepare_data_with_noise(signal, num_samples, noise_amplit
    return time, X_train, X_noisy
def build_autoencoder(input_shape):
    """Constructs a simple autoencoder model for noise reduction."""
   input_signal = Input(shape=input_shape) # Get the input shape of the signal
   # Encoder
   # Map the input signal to a representation
    encoded = Dense(256, activation='relu', activity_regularizer=12(0.01))(input
    encoded = Dropout(0.2)(encoded) # Dropout Layer to prevent overfitting
   encoded = Dense(128, activation='relu')(encoded) # Second Layer with 128 neu
   # Decoder
   # Map the representation back to the original signal
   decoded = Dense(256, activation='relu')(encoded)
    decoded = Dropout(0.2)(decoded)
    decoded = Dense(input_shape[0], activation='linear')(decoded) # linear activ
    autoencoder = Model(input_signal, decoded)
    autoencoder.compile(optimizer=Adam(learning_rate=0.001), loss=Huber())
   return autoencoder
def plot_signals(time, X_train, X_noisy, denoised_signals, signal_type, history)
    """Plots the original, noisy, denoised signals and the model's training hist
    plt.style.use('seaborn-v0_8-whitegrid')
    fig, axes = plt.subplots(3, 3, figsize=(15, 12))
    for i in range(3):
        axes[0, i].plot(time, X_noisy[i], color='gray', linestyle='-', alpha=0.5
        axes[0, i].fill_between(time, X_noisy[i], color='gray', alpha=0.2)
        axes[0, i].plot(time, X_train[i], color='blue', linestyle='-',alpha=0.3,
        axes[0, i].set_title(f'Original vs. Noisy {signal_type.upper()} (Example
        axes[0, i].set xlabel('Time (s)', fontsize=10)
        axes[0, i].set_ylabel('Amplitude', fontsize=10)
        axes[0, i].legend(loc='upper right', fontsize=8)
        axes[0, i].grid(axis='y', linestyle='--')
        axes[1, i].plot(time, X_noisy[i], color='gray', linestyle='-', alpha=0.5
        axes[1, i].fill_between(time, X_noisy[i], color='gray', alpha=0.2)
        axes[1, i].plot(time, denoised_signals[i], color='green', alpha=0.3,line
        axes[1, i].set_title(f'Denoised vs. Noisy {signal_type.upper()} (Example
        axes[1, i].set_xlabel('Time (s)', fontsize=10)
        axes[1, i].set_ylabel('Amplitude', fontsize=10)
        axes[1, i].legend(loc='upper right', fontsize=8)
        axes[1, i].grid(axis='y', linestyle='--')
```

```
axes[2, 0].plot(history.history['loss'], color='black')
   axes[2, 0].plot(history.history['val_loss'], color='orange')
   axes[2, 0].set_title('Model Error', fontsize=12)
   axes[2, 0].set_xlabel('Epochs', fontsize=10)
   axes[2, 0].set_ylabel('Error', fontsize=10)
   axes[2, 0].legend(['Train', 'Validation'], loc='upper right')
   axes[2, 0].grid(axis='y', linestyle='--')
   axes[2, 1].axis('off')
   axes[2, 2].axis('off')
   fig suptitle(f'Comparison of Original, Noisy, and Denoised {signal_type.uppe
    plt.tight_layout(rect=[0, 0, 1, 0.96])
   plt.show()
def main(signal_type):
   duration = 10
   frequency = 250
   num_samples = 1000
   noise_amplitude = 1.0
   time, X_train, X_noisy = prepare_data(
        duration,
        frequency,
        signal_type,
        num_samples,
        noise_amplitude
    )
   input_shape = (X_train.shape[1],)
   autoencoder = build_autoencoder(input_shape)
   early_stopping = EarlyStopping(
        monitor='val loss',
        patience=10,
        restore best weights=True
    )
   history = autoencoder.fit(
        X noisy,
        X_train,
        epochs=100,
        batch_size=128,
        validation_split=0.3,
        callbacks=[early_stopping]
   )
    denoised_signals = autoencoder.predict(X_noisy)
    plot_signals(time, X_train, X_noisy, denoised_signals, signal_type, history)
if __name__ == "__main__":
   for signal_type in ['ecg', 'eeg', 'emg', 'eog']:
        main(signal_type)
```

```
Epoch 1/100
6/6
                         2s 83ms/step - loss: 546.0801 - val_loss: 79.8028
Epoch 2/100
6/6
                         0s 35ms/step - loss: 89.3280 - val_loss: 39.3147
Epoch 3/100
6/6
                         0s 37ms/step - loss: 29.1501 - val_loss: 13.3264
Epoch 4/100
6/6
                         0s 35ms/step - loss: 5.6501 - val_loss: 15.0359
Epoch 5/100
6/6
                        • 0s 52ms/step - loss: 5.3456 - val_loss: 8.8320
Epoch 6/100
                        • 0s 37ms/step - loss: 2.6671 - val_loss: 5.3543
6/6
Epoch 7/100
6/6
                        0s 36ms/step - loss: 1.2242 - val_loss: 3.3686
Epoch 8/100
6/6
                         0s 36ms/step - loss: 0.2816 - val_loss: 2.7514
Epoch 9/100
                         0s 37ms/step - loss: 0.1258 - val_loss: 1.8279
6/6
Epoch 10/100
6/6
                         0s 34ms/step - loss: 0.0246 - val_loss: 1.7438
Epoch 11/100
6/6
                         0s 35ms/step - loss: 0.0171 - val_loss: 1.6267
Epoch 12/100
6/6
                         0s 36ms/step - loss: 0.0133 - val_loss: 1.3894
Epoch 13/100
                         0s 43ms/step - loss: 0.0020 - val_loss: 1.3283
6/6
Epoch 14/100
6/6
                        0s 57ms/step - loss: 0.0017 - val_loss: 1.2668
Epoch 15/100
6/6
                         0s 35ms/step - loss: 0.0012 - val_loss: 1.2611
Epoch 16/100
6/6
                         0s 36ms/step - loss: 0.0010 - val_loss: 1.2590
Epoch 17/100
6/6
                         0s 39ms/step - loss: 0.0010 - val_loss: 1.2581
Epoch 18/100
6/6
                        • 0s 37ms/step - loss: 9.2884e-04 - val_loss: 1.2576
Epoch 19/100
                         0s 40ms/step - loss: 9.6955e-04 - val_loss: 1.2571
6/6
Epoch 20/100
6/6 -
                        0s 36ms/step - loss: 9.7893e-04 - val_loss: 1.2569
Epoch 21/100
6/6
                        0s 37ms/step - loss: 9.2560e-04 - val_loss: 1.2568
Epoch 22/100
6/6
                         0s 34ms/step - loss: 9.0873e-04 - val_loss: 1.2569
Epoch 23/100
                         0s 53ms/step - loss: 9.1330e-04 - val_loss: 1.2568
6/6
Epoch 24/100
                         0s 35ms/step - loss: 9.2316e-04 - val loss: 1.2567
6/6 -
Epoch 25/100
6/6
                        0s 32ms/step - loss: 9.7719e-04 - val_loss: 1.2567
Epoch 26/100
6/6
                        0s 35ms/step - loss: 8.9853e-04 - val_loss: 1.2568
Epoch 27/100
                        0s 35ms/step - loss: 8.8854e-04 - val_loss: 1.2567
6/6
Epoch 28/100
6/6
                        0s 43ms/step - loss: 8.9609e-04 - val_loss: 1.2567
Epoch 29/100
6/6
                        • 0s 35ms/step - loss: 8.8722e-04 - val_loss: 1.2568
Epoch 30/100
                        • 0s 35ms/step - loss: 8.7152e-04 - val_loss: 1.2568
6/6
```

```
Epoch 31/100
6/6 -
                        - 0s 35ms/step - loss: 9.0248e-04 - val_loss: 1.2567
Epoch 32/100
6/6 -
                        - 0s 35ms/step - loss: 9.1162e-04 - val_loss: 1.2567
Epoch 33/100
                        - 0s 44ms/step - loss: 8.3957e-04 - val_loss: 1.2568
6/6
Epoch 34/100
                        - 0s 37ms/step - loss: 8.6062e-04 - val_loss: 1.2568
6/6 -
Epoch 35/100
6/6 -
                        - 0s 34ms/step - loss: 9.0151e-04 - val_loss: 1.2567
Epoch 36/100
6/6 -
                        - 0s 34ms/step - loss: 8.4756e-04 - val_loss: 1.2568
Epoch 37/100
6/6 -
                        - 0s 35ms/step - loss: 8.1085e-04 - val_loss: 1.2568
32/32 -
                          - 0s 4ms/step
```

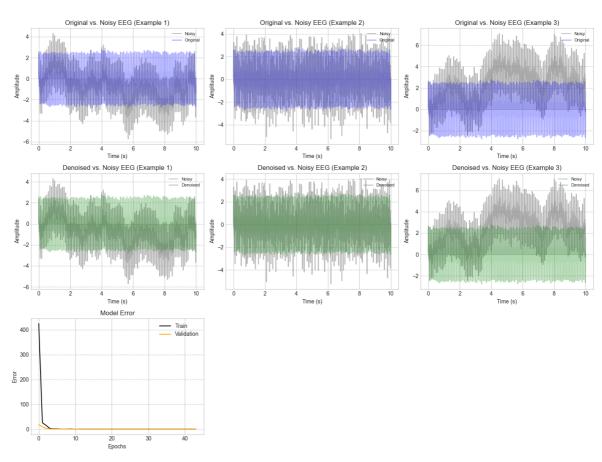
Comparison of Original, Noisy, and Denoised ECG Signals & Model Error



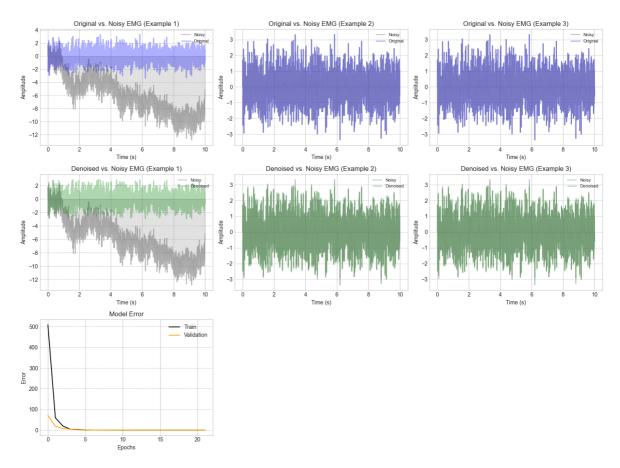
```
Epoch 1/100
6/6
                         2s 74ms/step - loss: 685.8409 - val_loss: 17.9598
Epoch 2/100
6/6
                        0s 39ms/step - loss: 26.9819 - val_loss: 9.4819
Epoch 3/100
6/6
                        0s 41ms/step - loss: 16.0336 - val_loss: 2.6408
Epoch 4/100
6/6
                         0s 38ms/step - loss: 3.0089 - val_loss: 0.8843
Epoch 5/100
6/6
                        • 0s 42ms/step - loss: 2.0784 - val_loss: 0.6186
Epoch 6/100
                        • 0s 40ms/step - loss: 1.2711 - val_loss: 0.3699
6/6
Epoch 7/100
6/6
                        0s 46ms/step - loss: 0.4529 - val_loss: 0.2616
Epoch 8/100
6/6
                         0s 41ms/step - loss: 0.3848 - val_loss: 0.2317
Epoch 9/100
                         0s 41ms/step - loss: 0.3252 - val_loss: 0.0311
6/6
Epoch 10/100
6/6
                         0s 39ms/step - loss: 0.3686 - val_loss: 0.0133
Epoch 11/100
6/6
                         0s 38ms/step - loss: 0.0525 - val_loss: 0.5323
Epoch 12/100
6/6
                         0s 38ms/step - loss: 0.7526 - val_loss: 0.0077
Epoch 13/100
                         0s 39ms/step - loss: 0.0086 - val_loss: 0.0027
6/6
Epoch 14/100
6/6
                        0s 40ms/step - loss: 0.0045 - val_loss: 0.0018
Epoch 15/100
6/6
                        0s 39ms/step - loss: 0.0039 - val_loss: 5.4709e-04
Epoch 16/100
6/6
                        0s 42ms/step - loss: 0.0164 - val_loss: 5.4151e-04
Epoch 17/100
6/6
                         0s 62ms/step - loss: 0.0025 - val_loss: 3.5429e-04
Epoch 18/100
6/6
                        0s 40ms/step - loss: 0.0022 - val_loss: 1.2946e-04
Epoch 19/100
                         0s 38ms/step - loss: 0.0023 - val_loss: 6.5058e-05
6/6
Epoch 20/100
6/6 -
                        0s 39ms/step - loss: 0.0021 - val_loss: 5.5797e-05
Epoch 21/100
6/6
                        0s 45ms/step - loss: 0.0020 - val_loss: 3.9620e-05
Epoch 22/100
6/6
                        0s 39ms/step - loss: 0.0020 - val_loss: 1.6767e-05
Epoch 23/100
                         0s 39ms/step - loss: 0.0021 - val_loss: 1.0588e-05
6/6
Epoch 24/100
6/6 -
                         0s 44ms/step - loss: 0.0020 - val loss: 1.0989e-05
Epoch 25/100
6/6
                        0s 40ms/step - loss: 0.0020 - val_loss: 1.2260e-05
Epoch 26/100
6/6
                        0s 56ms/step - loss: 0.0020 - val_loss: 7.0832e-06
Epoch 27/100
                        0s 39ms/step - loss: 0.0019 - val_loss: 1.0622e-05
6/6
Epoch 28/100
                        0s 39ms/step - loss: 0.0019 - val_loss: 3.0790e-05
6/6
Epoch 29/100
6/6
                        • 0s 39ms/step - loss: 0.0019 - val_loss: 7.7882e-06
Epoch 30/100
                        • 0s 39ms/step - loss: 0.0020 - val_loss: 3.8943e-06
6/6
```

Epoch 31/100			
6/6	0s 40ms/step - loss: 0.0018 - val_loss: 1.654	40e-05	
•	• 0s 43ms/step - loss: 0.0019 - val_loss: 1.452	27e-05	
Epoch 33/100			
	0s 40ms/step - loss: 0.0019 - val_loss: 1.119	96e-05	
Epoch 34/100	• 0s 40ms/step - loss: 0.0018 - val_loss: 3.08	58e-06	
Epoch 35/100	05 (0.115), 5 (cp 1055), 0 (0010 Vul_1055), 5 (00	,00	
	0s 54ms/step - loss: 0.0018 - val_loss: 5.370	ð7е-06	
Epoch 36/100	• 0s 40ms/step - loss: 0.0018 - val_loss: 5.193	290 06	
Epoch 37/100	45 40ms/step - 10ss. 0.0016 - Vai_10ss. 3.15.	306-00	
•	0s 39ms/step - loss: 0.0018 - val_loss: 1.380	∂6e-05	
Epoch 38/100	0. 20 // 1 0.0000 1.1 2.20		
Epoch 39/100	• 0s 38ms/step - loss: 0.0018 - val_loss: 3.216	o3e-06	
•	• 0s 38ms/step - loss: 0.0019 - val_loss: 3.130	63e-06	
Epoch 40/100			
6/6 Epoch 41/100	0s 42ms/step - loss: 0.0019 - val_loss: 3.068	31e-05	
	• 0s 43ms/step - loss: 0.0018 - val_loss: 1.50	27e-05	
Epoch 42/100			
	Os 40ms/step - loss: 0.0019 - val_loss: 3.64	36e-06	
Epoch 43/100	• 0s 39ms/step - loss: 0.0018 - val_loss: 8.67	500-06	
Epoch 44/100	03 35m3/3tep - 1033. 0.0010 - Val_1033. 0.0/.	796-00	
6/6	0s 57ms/step - loss: 0.0018 - val_loss: 3.499	99e-06	
32/32 — Os 4ms/step			





```
Epoch 1/100
6/6
                         2s 78ms/step - loss: 772.2092 - val_loss: 70.8118
Epoch 2/100
6/6
                        - 0s 78ms/step - loss: 83.2332 - val_loss: 18.5554
Epoch 3/100
6/6
                        • 0s 51ms/step - loss: 16.0611 - val_loss: 7.4550
Epoch 4/100
6/6
                         0s 44ms/step - loss: 4.1333 - val_loss: 4.8868
Epoch 5/100
6/6
                        - 0s 44ms/step - loss: 2.4021 - val_loss: 1.1809
Epoch 6/100
                        - 0s 38ms/step - loss: 0.6207 - val_loss: 1.1634
6/6 -
Epoch 7/100
                        - 0s 38ms/step - loss: 0.3396 - val_loss: 0.5388
6/6
Epoch 8/100
6/6 -
                        • 0s 38ms/step - loss: 0.1953 - val_loss: 0.5093
Epoch 9/100
6/6 -
                        • 0s 38ms/step - loss: 0.0835 - val_loss: 0.3190
Epoch 10/100
6/6
                         0s 40ms/step - loss: 0.2216 - val_loss: 0.1410
Epoch 11/100
6/6
                         0s 38ms/step - loss: 0.0088 - val_loss: 0.8434
Epoch 12/100
                        0s 46ms/step - loss: 0.2270 - val_loss: 0.1249
6/6
Epoch 13/100
                        • 0s 38ms/step - loss: 0.0037 - val_loss: 0.1274
6/6 -
Epoch 14/100
6/6
                        • 0s 40ms/step - loss: 0.0028 - val_loss: 0.1282
Epoch 15/100
6/6
                        - 0s 38ms/step - loss: 0.0020 - val_loss: 0.1288
Epoch 16/100
6/6
                        • 0s 37ms/step - loss: 0.0018 - val_loss: 0.1294
Epoch 17/100
6/6 -
                         0s 37ms/step - loss: 0.0016 - val_loss: 0.1297
Epoch 18/100
6/6 -
                        - 0s 38ms/step - loss: 0.0015 - val_loss: 0.1299
Epoch 19/100
                        • 0s 38ms/step - loss: 0.0015 - val_loss: 0.1300
6/6 -
Epoch 20/100
6/6 -
                        • 0s 54ms/step - loss: 0.0014 - val_loss: 0.1300
Epoch 21/100
6/6
                        • 0s 37ms/step - loss: 0.0014 - val_loss: 0.1301
Epoch 22/100
6/6
                         0s 36ms/step - loss: 0.0015 - val_loss: 0.1301
32/32 -
                          - 0s 5ms/step
```



```
Epoch 1/100
6/6
                         2s 71ms/step - loss: 573.3018 - val_loss: 74.4102
Epoch 2/100
6/6
                         0s 40ms/step - loss: 57.4258 - val_loss: 15.3606
Epoch 3/100
6/6
                        0s 38ms/step - loss: 6.7631 - val_loss: 5.3075
Epoch 4/100
6/6
                         0s 36ms/step - loss: 5.2462 - val_loss: 2.6910
Epoch 5/100
6/6
                        • 0s 37ms/step - loss: 1.2287 - val_loss: 0.9434
Epoch 6/100
                        • 0s 36ms/step - loss: 0.3373 - val_loss: 0.5983
6/6
Epoch 7/100
6/6
                        0s 36ms/step - loss: 0.4096 - val_loss: 0.1848
Epoch 8/100
6/6
                         0s 35ms/step - loss: 0.0474 - val_loss: 0.2290
Epoch 9/100
                         0s 46ms/step - loss: 0.2496 - val_loss: 0.1025
6/6
Epoch 10/100
6/6
                         0s 38ms/step - loss: 0.0348 - val_loss: 0.0472
Epoch 11/100
6/6
                         0s 39ms/step - loss: 0.0524 - val_loss: 0.0524
Epoch 12/100
6/6
                         0s 42ms/step - loss: 0.0050 - val_loss: 0.1195
Epoch 13/100
                         0s 36ms/step - loss: 0.0573 - val_loss: 0.0469
6/6
Epoch 14/100
6/6
                        0s 37ms/step - loss: 0.0020 - val_loss: 0.0482
Epoch 15/100
6/6
                         0s 36ms/step - loss: 0.0016 - val_loss: 0.0636
Epoch 16/100
6/6
                         0s 37ms/step - loss: 0.0020 - val_loss: 0.0496
Epoch 17/100
6/6
                         0s 38ms/step - loss: 0.0059 - val_loss: 0.0432
Epoch 18/100
6/6
                        • 0s 36ms/step - loss: 0.0012 - val_loss: 0.0422
Epoch 19/100
                         0s 49ms/step - loss: 0.0012 - val_loss: 0.0985
6/6
Epoch 20/100
6/6 -
                        0s 37ms/step - loss: 0.0159 - val_loss: 0.0415
Epoch 21/100
6/6
                        0s 39ms/step - loss: 0.0011 - val_loss: 0.0900
Epoch 22/100
6/6
                         0s 38ms/step - loss: 0.0604 - val_loss: 0.0413
Epoch 23/100
                         0s 36ms/step - loss: 0.0013 - val_loss: 0.6500
6/6
Epoch 24/100
                         0s 36ms/step - loss: 0.3137 - val loss: 0.0412
6/6 -
Epoch 25/100
6/6
                        0s 36ms/step - loss: 0.0057 - val_loss: 2.0062
Epoch 26/100
6/6
                         0s 35ms/step - loss: 1.0233 - val_loss: 0.2979
Epoch 27/100
                        0s 36ms/step - loss: 0.3517 - val_loss: 0.0411
6/6
Epoch 28/100
6/6
                        0s 36ms/step - loss: 0.0011 - val_loss: 0.0411
Epoch 29/100
6/6
                        • 0s 53ms/step - loss: 0.0011 - val_loss: 0.0410
Epoch 30/100
                         0s 41ms/step - loss: 0.0011 - val_loss: 0.0410
6/6
```

Epoch 31/100		
	0s 35ms/step - loss: 0.0010 - val_loss: 0.0410	
Epoch 32/100	0s 37ms/step - loss: 0.0011 - val_loss: 0.0410	
Epoch 33/100	03 37m3, 3 ccp 1033. 0.0011 vai_1033. 0.0410	
6/6	0s 36ms/step - loss: 0.0010 - val_loss: 0.0410	
Epoch 34/100		
	0s 37ms/step - loss: 0.0011 - val_loss: 0.0410	
Epoch 35/100	0s 35ms/step - loss: 0.0010 - val_loss: 0.0410	
Epoch 36/100	03 55m3, 5ccp 1033. 0.0010 vai_1033. 0.0410	
	0s 37ms/step - loss: 0.0011 - val_loss: 0.0410	
Epoch 37/100		
	0s 36ms/step - loss: 0.0011 - val_loss: 0.0410	
Epoch 38/100	0s 45ms/step - loss: 0.0011 - val_loss: 0.0410	
Epoch 39/100	03 +3m3, 5 ccp 1033. 0.0011 vai_1033. 0.0410	
•	0s 36ms/step - loss: 0.0010 - val_loss: 0.0410	
Epoch 40/100		
	0s 39ms/step - loss: 0.0010 - val_loss: 0.0410	
Epoch 41/100	0s 38ms/step - loss: 0.0010 - val_loss: 0.0410	
Epoch 42/100	03 30m3/3cep - 1033. 0.0010 - Val_1033. 0.0410	
	0s 37ms/step - loss: 9.7657e-04 - val_loss: 0.0410	
Epoch 43/100		
	0s 38ms/step - loss: 0.0010 - val_loss: 0.0410	
Epoch 44/100	0s 36ms/step - loss: 0.0010 - val_loss: 0.0410	
	— 0s 4ms/step	
Comparison of Original Noisy and Denoised FOG Signals & Model From		



